

STATISTICAL AND MATHEMATICAL METHODS FOR ARTIFICIAL INTELLIGENCE

Analisi Comparativa per Riduzione Dimensionale

Approccio Lineare e Non-Lineare per
Riconoscimento e Verifica Facciale

Roberto Carriero, Massimiliano Leone

Laurea Magistrale in Ingegneria Informatica – Artificial Intelligence and Data Science

Docente: Prof.ssa Marina Popolizio

A.A. 2025/2026

Indice

Struttura della presentazione

1 Introduzione e Motivazioni

Contesto applicativo, maledizione della dimensionalità, obiettivi del progetto

3 Dataset e Preprocessing

LFW, sbilanciamento classi, pipeline di preprocessing, faccia media

5 Risultati: Riconoscimento Facciale

Protocollo sperimentale, risultati quantitativi, curve ROC e matrici di confusione

2 Framework Matematico

PCA, SVD, Autoencoder, SVM, Neural Network, metriche di similarità

4 Esperimenti: Riduzione Dimensionale

Studio di ablazione PCA, eigenfaces, addestramento modelli, confronto di ricostruzione

6 Risultati: Verifica Facciale

Setup di verifica, distanza euclidea vs similarità del coseno, distribuzione di similarità, heatmap



Obiettivo

Confronto tra **PCA (lineare)** e **Autoencoder (non-lineare)** per riduzione dimensionale in ambito di riconoscimento e verifica facciale

01

Obiettivi del Progetto

Fasi principali dello studio

1 Riduzione Dimensionale

PCA (SVD) vs Autoencoder

Confronto tra approccio lineare e non-lineare

📈 Analisi della varianza spiegata e MSE ricostruzione

2 Classificazione

SVM vs Rete Neurale (NN)

Valutazione di classificatori lineari e non-lineari su feature ridotte

📊 Accuratezza, F1-Score, curva ROC-AUC

3 Verifica Facciale

Distanza Euclidea vs Similarità del Coseno

Confronto tra metriche di similarità per task di verifica

⚖️ EER, AUC, TAR, FAR

4 Studio di Ablazione

Analisi Componenti e Parametri

Variazioni al numero di componenti, architettura, iperparametri

🔍 Grid Search e Cross-Validation

?

Tesi della Ricerca

Un metodo **non-lineare (Autoencoder)** supera sempre il **lineare (PCA)**, oppure esistono condizioni in cui la **semplicità vince?**

Applicazione



Sicurezza

Controllo degli accessi, sorveglianza, autenticazione biometrica



Dispositivi Mobili

Sblocco smartphone (Face ID), app di autenticazione



Sistemi Embedded

Dispositivi a bassa potenza, IoT, edge computing



Requisiti Chiave

1

Modelli leggeri e veloci

Inferenza in tempo reale su dispositivi con risorse limitate

2

Riduzione dimensionale

Compressione feature per efficienza

3

Alta accuratezza

Precisione nel riconoscimento e robustezza alle variazioni



Approfondimento: Dispositivi Edge



Ampia Distribuzione

Dispositivi con memoria limitata



Bassa Latenza

Inferenza rapida in tempo reale



Consumo Energetico

Meno calcoli = meno energia



Spazio Ridotto

Meno dati e più compatti

Formulazione del Problema

Input

Immagine $X \in \mathbb{R}^D$

Output

Identità $\hat{y} \in \{1, \dots, K\}$

Metriche di Valutazione

- 1 Accuratezza**
Predizione corrette vs numero totale di esempi osservati
- 2 F1-Score Ponderato**
Media pesata per gestire sbilanciamento classi
- 3 ROC-AUC**
Classificazione multiclasse (OvR) con micro/macro averaging
- 4 Matrice di Confusione**
Analisi dettagliata degli errori per classe



Scenario

Dataset con **K identità**: l'immagine in input viene associata a una di queste

Dataset

K = 7 classi

04

Task 2: Verifica Facciale (1:1)

Verifica se due volti appartengono alla stessa persona

↔ Formulazione del Problema

Input

Coppia di immagini (x_1, x_2)

Output

Decisione binaria $d \in \{\text{Genuine}, \text{Impostor}\}$

Regola di Decisione

$d = \text{Genuine}$, se $S(x_1, x_2) \geq \tau$

$d = \text{Impostor}$, altrimenti

📈 Metriche Specifiche

⚖️ EER (Equal Error Rate)

Punto in cui FAR = FRR

Soglia ottima τ^* dove i due errori si equivalgono

📊 ROC / AUC

Area sottesa alla curva ROC di verifica

🎯 TAR-FAR

True Accept Rate, fissato un certo False Accept Rate (es. 0.1%)



Coppia Genuina

Stessa identità → Similarità alta



Coppia Impostore

Identità diverse → Similarità bassa

Problema: Maledizione della Dimensionalità

Sfida matematica in spazi ad alta dimensionalità

⚠ Sfida Matematica

Esempio Concreto

Immagine **64 x 47 pixel** – **D = 3008** dimensioni

Ogni immagine è un punto in uno spazio 3008-dimensionale

- **Spazio delle feature intrinsecamente sparso**
La maggior parte dello spazio è vuoto, i dati occupano una frazione infinitesimale
- **Volume concentrato sui bordi dell'ipercubo**
Il volume si concentra nelle regioni estreme
- **Dati necessari crescono esponenzialmente**
Per coprire lo spazio servono $O(e^D)$ campioni

Riepilogo

1. Distanze perdono significato

Tutti i punti diventano «equidistanti»

2. Classificatori perdono potere

Overfitting più probabile

3. Distanze non discriminanti

Similarità non significative



Soluzione: Riduzione Dimensionale

Proiettare i dati in uno spazio di dimensione inferiore preservando l'informazione rilevante



Definizione

Dato un dataset $X \in \mathbb{R}^{N \times D}$, trovare una rappresentazione $Z \in \mathbb{R}^{N \times k}$ con $k \ll D$ che preservi l'informazione rilevante



Approccio Lineare (PCA)

$$Z = XW, W \in \mathbb{R}^{D \times k}$$

- ✓ **Trasformazione affine** – Proiezione lineare su un sottospazio
- ✓ **Preserva varianza** – Massimizza informazione contenuta
- ✓ **Soluzione analitica** – Chiusa e deterministica



Approccio Non-Lineare (Autoencoder)

$$Z = f_{\theta}(X), f: \mathbb{R}^D \rightarrow \mathbb{R}^k$$

- ✓ **Trasformazione non-lineare** – Funzioni di attivazione
- ✓ **Apprende manifold curvi** – Strutture non-lineari
- ✓ **Soluzione iterativa** – Iterativa (discesa del gradiente)

🎯 Massimizzazione della Varianza

Si cercano le direzioni nello spazio che massimizzino la varianza dei dati proiettati

Si utilizza la matrice di covarianza dei dati centrati

$$\Sigma = (1/(N-1)) X_{cT} X_c$$

🔑 Soluzione

Gli **autovettori** di Σ corrispondono ai **k autovalori più grandi**:

$$\Sigma v_i = \lambda_i v_i, \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_k$$

📌 Gli autovettori costituiscono le **componenti principali**

★ Proprietà

Problema Convesso

Soluzione **globalmente ottima** e **unica**

Ortogonalità

Le componenti sono tra loro ortogonali: $v_i \perp v_j$

Ordinamento

λ_1 cattura la massima varianza, λ_2 la seconda, etc.

Singular Value Decomposition (SVD)

Decomposizione matriciale ai valori singolari per efficienza computazionale

Teorema SVD

Ogni matrice $X \in \mathbb{R}^{N \times D}$ può essere decomposta come:

$$X = U \Sigma V^T$$

Matrice Ortogonale

$$U \in \mathbb{R}^{N \times N}$$

Vettori singolari sinistri

Colonne = autovettori di $X X^T$

Matrice Diagonale

$$\Sigma \in \mathbb{R}^{N \times D}$$

Valori singolari σ_i

$$\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_{\min(N, D)} \geq 0$$

Matrice Ortogonale

$$V \in \mathbb{R}^{D \times D}$$

Vettori singolari destri

Colonne = autovettori di $X^T X$



Relazione con Autovalori

$\sigma_i = \sqrt{\lambda_i(N-1)}$ dove λ_i è l'autovalore di Σ (matrice di covarianza)

</> Implementazione

1 Centra i dati

$X_c = X - \mu$ dove $\mu = (1/N) \sum_i x_i$

2 Calcola SVD

$X_c = U \Sigma V^T$

3 Seleziona V_k

Prime **k colonne** di V : $V_k \in \mathbb{R}^{D \times k}$

4 Proietta

$Z = X_c V_k$

⇔ Trasformazioni

↓ Proiezione

$$Z = X_c V_k \in \mathbb{R}^{N \times k}$$

Da D dimensioni a k dimensioni

↑ Ricostruzione

$$\hat{X} = Z V_k^T + \mu$$

Torna allo spazio originale



Vantaggi SVD vs Decomposizione agli Autovalori

Stabilità numerica ed efficienza computazionale. Evita il calcolo esplicito di Σ

Varianza Spiegata Cumulativa

Quanta informazione viene preservata?

📊 Varianza Spiegata

Per ogni componente i:

$$\text{EVR}_i = \sigma_i^2 / \sum_j \sigma_j^2$$


- 📌 **Frazione di varianza** catturata dalla componente i-esima
- 📈 Somma di tutti gli EVR = **1 (100%)**

📈 Varianza Cumulativa

Con k componenti:

$$\text{CVR}(k) = \sum_{i=1:k} \text{EVR}_i$$

- ✅ **Varianza totale** preservata con k componenti
- 💡 Utile per scegliere il numero ottimale di componenti



Obiettivo

90-95% varianza



Definizione

Un autoencoder $A = (f_\theta, g_\varphi)$ è composto da:

Encoder f_θ

$$f_\theta: \mathbb{R}^D \rightarrow \mathbb{R}^k$$

$$z = f_\theta(x) = \sigma(W_e x + b_e)$$

→ **Comprime** l'input in rappresentazione latente

→ Parametri: W_e, b_e

Decoder g_φ

$$g_\varphi: \mathbb{R}^k \rightarrow \mathbb{R}^D$$

$$\hat{x} = g_\varphi(z) = \sigma(W_d z + b_d)$$

→ **Ricostruisce** l'input dalla rappresentazione

→ Parametri: W_d, b_d



Architettura

$D = 3008 \rightarrow 256 \rightarrow 128 \rightarrow k=100 \rightarrow 128 \rightarrow 256 \rightarrow D = 3008$

– Problema di Ottimizzazione (Non-Convesso)

Minimizzare l'errore di ricostruzione:

$$L(\theta, \varphi) = (1/N) \sum_i ||x(i) - g_{\varphi}(f_{\theta}(x(i)))||^2_2 + \lambda ||\theta, \varphi||^2_2$$

⚙️ Dettagli Implementativi

⚡ Funzione di Attivazione

LeakyReLU

🔄 Optimizer

Adam

📦 Batch Norm

Dopo ogni layer

🛡️ Regolarizzazione

✂️ Dropout

$p = 0.1$

🏋️ Weight Decay

$\lambda = 10^{-4}$

👋 Early Stopping

patience = 10

Confronto Teorico: PCA vs Autoencoder

Tabella comparativa dei due approcci

Caratteristica	PCA (SVD)	Autoencoder
Natura	Lineare	Non-lineare
Soluzione	Analitica (forma chiusa)	Iterativa (discesa del gradiente)
Ottimizzazione	Convessa	Non-convessa
Complessità*	$O(M \cdot N \cdot \min(M, N))$	$O(E \cdot M \cdot \theta)$
Interpretabilità	Alta (eigenfaces)	Bassa (black-box)
Dati richiesti	Pochi	Molti
Capacità	Sottospazi lineari	Manifold non-lineari

* M = numero di osservazioni

N = numero di feature

E = numero di epoche

$|\theta|$ = numero di parametri

» Similarità del Coseno

$$\text{sCos}(u,v) = (u \cdot v) / (\|u\|_2 \cdot \|v\|_2) \\ \in [-1, 1]$$

- ✓ **Invariante alla magnitudine** – Robusto alla scala
- ✓ Robusto a **variazioni di illuminazione**
- ✓ Cattura "**direzione semantica**"

Distanza Euclidea

$$\text{dEucl}(u,v) = \|u - v\|_2$$

- ! **Sensibile alla scala** – Magnitudine influisce
- ✓ **Interpretazione geometrica** diretta
- i **Distanza effettiva** nello spazio




Relazione Matematica

Per vettori unitari: $\|u - v\|_2^2 = 2(1 - \text{sCos}(u, v))$

Pipeline di Analisi Completa

Flusso operativo al variare del numero di componenti



Tecnologie Utilizzate



Python 3.14

NumPy, Pandas, Scikit-Learn, Matplotlib, PyTorch



Autoencoder

Rete neurale con PyTorch



PCA from scratch

Implementata con SVD, senza libreria Sci-kit Learn



Grid Search / Cross Validation

5 fold di validazione

Dataset: «Labeled Faces in the Wild» (LFW)

Stato dell'arte per il riconoscimento facciale



Caratteristiche



Standard per face recognition (in-the-wild)



Variabilità naturale: posa, illuminazione, espressione



Condizioni non controllate – Sfida realistica



Filtro Applicato

Solo identità con **≥ 70 immagini** per garantire supporto statistico adeguato



Nota

Distribuzione classi **sbilanciata**, richiede tecniche di gestione

Statistiche Finali

7

Classi

1288

Immagini Totali

1030

Train (80%)

258

Test (20%)

⚠ Problema

La classe "**George W. Bush**" domina il dataset con oltre il 40% delle immagini

Conseguenze

→ **Bias** verso la classe maggioritaria

→ **Sensibilità bassa** per classi minoritarie

🔧 Soluzioni Adottate

✂ Suddivisione stratificata

Mantiene **proporzioni** tra train e test

⚖ Peso delle classi

Ogni classe viene **pesata** per migliorarne la **rappresentatività**

📊 F1-Score ponderato

Metrica **robusta** allo sbilanciamento

Distribuzione delle Classi

Bush
530

Powell
236

Blair
144

Rumsfeld
121

Schroeder
109

Sharon
77

Chavez
71



Standardizzazione (Z-score)

$$z_i = (x_i - \mu) / \sigma$$

Motivazioni

- ✓ **Stabilità numerica** SVD
- ✓ **Convergenza rete neurale** più rapida
- ✓ **Comparabilità** feature

Suddivisione Stratificata

$$n_{\text{train}_k} / N_{\text{train}} \approx n_{\text{test}_k} / N_{\text{test}}$$

Importanza

- ! Cruciale per dataset **sbilanciati**
- 🛡️ Evita che classi rare siano **assenti nel test**
- ⚖️ Garantisce **rappresentatività**

📏 Dimensioni

Immagine originale

128 x 94 pixel

Dopo ridimensionamento

64 x 47 pixel

Vettore delle feature

D = 3008

Classi

K = 7

✂️ Partizionamento

Training Set

1030

80%

Test Set

258

20%

Stratificato per classe


📊 Statistiche dei Pixel

Intervallo originale

[0, 255]

Post-standardizzazione

$\mu = 0, \sigma = 1$



Compression Target

Da **3,008** a **100** dimensioni

Riduzione

≈ 97%

🎯 Interpretazione Geometrica

La **faccia media** è il **centroide** dello spazio vettoriale:

$$\mu \in \mathbb{R}^{3008}$$

Formulazione

$$\mu = (1/N) \sum_{i=1:N} x_i$$

🔍 Analisi Visiva



👁️ Zone Nitide

Strutture comuni e allineate tra i volti

☁️ Zone Sfocate

Alta varianza **inter-soggetto**

📈 PCA Sottrae μ

Componenti – **deviazioni** dalla media



Significato

La mean face rappresenta il **volto "medio"** del dataset. Ogni volto può essere visto come μ + variazioni

x^1 Formulazione Primale

$$\begin{aligned} \min & (1/2) ||w||^2 + C(1/N) \sum \xi_i \\ \text{s.t.} & y_i(w^T x_i + b) \geq 1 - \xi_i \end{aligned}$$

- ✓ **Problema convesso** – Soluzione globale unica
- ✓ Efficace su **piccoli dataset**
- ✓ **Supporto teorico** solido

○ Kernel RBF

$$K(x, x') = \exp(-\gamma ||x - x'||^2)$$

Iperparametri (Grid Search)

$$C \in \{0.1, 1, 10\}$$

$$\text{Kernel} \in \{\text{RBF}, \text{Linear}\}$$

$$\gamma \in \{\text{scale}, \text{auto}\}$$



Limitazione

Scalabilità limitata. Costoso su dataset grandi

Architettura

Input → [256] → [128] → [K]

 **Batch Norm** – Stabilizza il training

 **Dropout** – Previene overfitting

 **ReLU** – Non-linearità

Cross-Entropy Loss (Pesata)

$$L = -\sum w_{yi} \sum y_{ik} \log(\hat{p}_{ik})$$

Pesi per sbilanciamento:

$$w_{yi} = M / (K \cdot n_k)$$

 Più peso alle classi minoritarie

Iperparametri (Grid Search)

Hidden Layers

{(128, 64), (256, 128)}

Learning Rate

{ 10^{-2} , 10^{-3} }

Dropout

{0.1, 0.2}

Epochs

{50, 100}

Ottimizzazione dei Modelli

Validazione incrociata e ricerca dei migliori iperparametri



5-Fold CV
Stratificata



Grid Search
Ricerca Iperparametri



Ri-addestramento
Con migliori Iperparametri



Valutazione
Test Set



Configurazioni Testate



Combinazioni Totali

12

SVM



Combinazioni Totali

32

Rete Neurale

PCA: Studio di Ablazione


Analisi dell'impatto del numero di componenti

Osservazioni

- 1 Saturazione rapida**
Dopo **100 componenti** i benefici diventano marginali
- 2 Correlazione accuratezza – varianza**
Maggiore varianza spiegata = migliore accuratezza
- 3 Oltre k=100: rumore**
Componenti aggiuntive catturano **rumore non informativo**

Conclusione

100 componenti rappresentano il punto ottimale: alta compressione (97%) con minima perdita di informazione discriminante



Numero Componenti

k = 100


Varianza

90.2%

Accuratezza SVM

80.6%

Prime 12 Componenti Principali



Interpretazione

PC 1-2

Illuminazione globale – Variazione di luce

PC 3-6

Geometria – Simmetria, posizione delle feature

PC 7-12

Dettagli fini – Texture, micro-variazioni

Base Ortonormale

Le **eigenfaces** costituiscono una **base ortonormale** dello spazio dei volti

Ricostruzione

$$\mathbf{x} \approx \boldsymbol{\mu} + \sum_{i=1:k} c_i \mathbf{v}_i$$


 Ogni volto è una combinazione lineare delle eigenfaces

Convergenza

✓ **Convergenza stabile** – Nessuna oscillazione

⚖️ **Validation Loss $\approx$ Train Loss** – No overfitting evidente

👋 **Early stopping** – epoch 60



Tempo di Addestramento



Circa 5 minuti su CPU per convergenza completa con early stopping (2 minuti su GPU)


Osservazione

Il **minimo MSE** coincide con la **massima accuratezza** (k=100)

Interpretazione

✓ **Ricostruzione migliore** – più informazione preservata

⚠ **Oltre k=100**: sovra-parameterizzazione



Trade-off Ottimale

k=100 bilancia **rappresentatività** e **generalizzazione**. Più componenti non migliorano le performance ma aumentano il rischio di overfitting

Errore di Ricostruzione

Confronto dei volti ricostruiti dopo la riduzione dimensionale (Errore Quadratico Medio, MSE)

PCA

- ✓ **Geometricamente fedele** – Preserva struttura
- ⚠ **Artefatti ad alte frequenze** – Rumore nei dettagli
- ✓ **Preserva texture** – Mantieni pattern originali

MSE = 0.089

Autoencoder

- 🌊 **Effetto smoothing** – Immagini più morbide
- 📅 **MSE "media" incertezze** – Approccio conservativo
- ✗ **Perde micro-dettagli** – Dettagli fini sfocati

MSE = 0.127

Originale vs PCA vs Autoencoder



PCA vs Autoencoder: Confronto Qualitativo

Tabella riepilogativa delle prestazioni

Aspetto	PCA	Autoencoder
Accuratezza (SVM)	80.6%	79.8%
Errore di Ricostruzione (MSE)	0.089	0.127
Varianza spiegata	90.2%	N/A
Tempo di Addestramento	< 1 sec	~ 2 min



Osservazione Chiave

Per questo dataset, **PCA è competitivo** con l'Autoencoder nonostante la linearità. La semplicità vince quando i dati hanno struttura lineare

PCA vs Autoencoder: Confronto Quantitativo

Prestazione dei 4 modelli testati

Modello	Feature	Accuratezza	F1-Score	ROC-AUC	95% Int. Confid.	CV Fold Acc.
Rete Neurale	PCA	0.849	0.852	0.981	[0.80, 0.89]	0.859
Rete Neurale	Autoencoder	0.818	0.820	0.972	[0.77, 0.86]	0.798
SVM	PCA	0.806	0.802	0.980	[0.76, 0.85]	0.815
SVM	Autoencoder	0.798	0.794	0.971	[0.75, 0.84]	0.779



Vincitore
Neural Network + PCA

Accuratezza: **85%**
F1-Score: 85.2% | ROC-AUC: 98.1%

? Risultato Contro-intuitivo

Perché il metodo **lineare (PCA)** batte quello **non-lineare (AE)**?

1 Dataset Allineato

LFW ha volti **già centrati**. La variabilità principale è **lineare** (illuminazione, posa)

2 Scarsità dei Dati

1,288 samples sono insufficienti per addestrare AE complessi. Rischio di **overfitting**

3 Approccio Ibrido

Rete Neurale su feature PCA consente decisioni non-lineari su feature lineari robuste

✂ Rasoio di Occam

Principio applicato al Machine Learning

«Un modello **semplice** che spiega i dati è migliore di un modello **complesso** che overfitta: la semplicità è la più grande complessità»


Interpretazione

✓ Tutte le classi: $AUC \geq 0.95$

★ Hugo Chavez: $AUC \approx 1.00$

👍 Separabilità quasi lineare

Schema **One-vs-Rest**



Significato

Elevato AUC indica **ottima capacità discriminativa** del modello su tutte le classi


↑ Miglioramenti rispetto a SVM

📈 Prestazioni superiori ed alto TPR

🔗 Confini decisionali più flessibili

👥 Migliore gestione classi difficili

Schema **One-vs-Rest**



Modello Migliore
Neural Network + PCA

0.981
AUC

Q Pattern Errori

✓ **Diagonale dominante** – Predizioni corrette

↔ **Confusione:** Powell – Bush

i Nota

La confusione tra Powell e Bush è dovuta alla **somiglianza visiva** e alla **dominanza della classe Bush** nel dataset




≠ Confronto con PCA

✗ Più elementi **fuori diagonale**

👤 Confusione **classi minoritarie**

Spiegazione

AE **comprime troppo**, perdendo **discriminatività inter-classe**



Conclusione

L'Autoencoder, pur essendo più complesso, **non riesce a catturare** la struttura discriminante del dataset quanto la PCA

Protocollo

1 Generazione Coppie

1,000 coppie bilanciate:

- 500 **Genuine** (stessa identità)
- 500 **Impostori** (identità diverse)

2 Calcolo Similarità

Per ogni coppia calcolare **similarità** nello spazio latente

3 Determinazione Soglia

Soglia ottima τ^* al punto **EER**

Equal Error Rate (EER)

Punto in cui:

$$\text{FAR}(\tau^*) = \text{FRR}(\tau^*)$$

FAR (False Accept Rate)

Impostor accettato

FRR (False Reject Rate)

Genuine rifiutato



Metriche Testate

Similarità del Coseno vs **Distanza Euclidea** per determinare quale metrica è più robusta

Euclidea vs Coseno: Confronto

Quale metrica di similarità performa meglio?

» Similarità del Coseno

Risultati

AUC
0.94

EER
8.2%

Distanza Euclidea

Risultati

AUC
0.91

EER
11.5%



Vincitore

Similarità del Coseno performa meglio per verifica facciale (AUC 0.94 vs 0.91, EER 8.2% vs 11.5%)

Distribuzione di Similarità

Separazione Genuini vs Impostori

Interpretazione


✓ **Doppia distribuzione** tra genuini e impostori

⚙ **Soglia:** $\tau^* \approx 0.147$

✗ **Sovrapposizioni:** errore irriducibile

EER $\approx 8\%$

Sistema per sicurezza media



Significato

EER = 8% indica un sistema **utilizzabile per sicurezza media** (es. accesso smartphone) ma non per applicazioni critiche

✓ Coppie Genuine

Coppie con **stessa identità** – Similarità alta

Genuine
Score: 0.728



Genuine
Score: 0.759



Genuine
Score: 0.760



Genuine
Score: 0.811



✗ Coppie Impostori

Coppie con **identità diverse** – Similarità bassa

Impostor
Score: 0.654



Impostor
Score: 0.670



Impostor
Score: 0.702



Impostor
Score: 0.743



Heatmap Inter-Classe: PCA

Similarità media tra classi diverse

Analisi


■ **Diagonale verde scuro** (≈ 1) – Alta auto-similarità

■ **Valori in rosso** (< 0) – Bassa similarità inter-classe

✚ Classi proiettate in **direzioni ortogonali**

Interpretazione

Ottima separabilità inter-classe



Conclusione

✓ PCA produce feature con **ottima separabilità inter-classe**, ideale per classificazione e verifica

Heatmap Inter-Class: Autoencoder

Confronto rispetto alla PCA

≠ Confronto con PCA


Colori più chiari **fuori diagonale**

↑ **Similarità inter-classe** maggiore

✚ Meno **separabilità**

Interpretazione

AE mappa identità diverse in **regioni più vicine** nello spazio latente



Problema

L'Autoencoder produce feature con maggior sovrapposizione tra classi, riducendo il potere discriminante

Verifica Facciale: Riepilogo

Confronto completo delle metriche ottenute

Feature	Similarità / Distanza	AUC	EER	Soglia
PCA	Coseno	0.94	8.2%	0.147
PCA	Euclidea	0.91	11.5%	12.3
Autoencoder	Coseno	0.89	12.1%	0.203
Autoencoder	Euclidea	0.86	15.8%	8.7



Migliore

PCA + Similarità del Coseno



Conclusione

Per la verifica facciale, le **feature lineari** sono più robuste



Il gap tra PCA e AE è più marcato nella verifica che nel riconoscimento facciale, confermando la maggiore rappresentatività delle feature PCA

1 Compressione 97%

Da **3008 a 100 dimensioni**, accuratezza > 84%. Dimostrazione dell'efficacia della riduzione dimensionale

2 Linearità

PCA supera Autoencoder su dataset piccolo e allineato. La semplicità vince quando i dati lo consentono

3 Soluzione Ibrida

Feature PCA + Classificatore NN è la combinazione ottimale. Unisce le caratteristiche migliori di entrambi gli approcci

4 Coseno > Euclidea

Per la verifica facciale, l'**invarianza alla scala dei dati** è fondamentale. La similarità del coseno performa meglio

5

EER 8%

Sistema utilizzabile per sicurezza media

85%

Accuratezza Migliore

Limitazioni

-  **Autoencoder:** ignora struttura 2D delle immagini
-  **Dataset limitato:** 1288 samples insufficienti per AE complessi
-  **Sbilanciamento:** impatta la sensibilità delle classi minoritarie

Direzioni Future

-  **Autoencoder convoluzionale:** sfrutta correlazioni spaziali
-  **Transfer Learning:** pre-training su dataset grandi
-  **Stress Test:** testare i modelli con rumore (gaussiano o S-P)



Prospettiva

Con **più dati**, l'approccio non-lineare potrebbe superare il lineare. Il potenziale dell'AE non è stato pienamente sfruttato con il dataset analizzato

1

Non sempre non-lineare è meglio di lineare

Dipende dai dati: Dataset piccoli e allineati favoriscono **metodi semplici**

2

La riduzione dimensionale è cruciale

97% compressione con minima perdita

3

Gli approcci ibridi possono essere vincenti

Rete neurale su feature PCA si è rivelata la combinazione ottimale

4

La metrica conta

Similarità del coseno e **distanza Euclidea** hanno comportamenti diversi. Scegliere in base al problema

5

La validazione è essenziale

Valutare **validazione incrociata** e **intervalli di confidenza** per risultati affidabili

Extra 1: Classificazione sui Dati Originali

Analisi delle prestazioni sulle immagini prima della riduzione dimensionale

I modelli **SVM e NN** sono stati **ri-addestrati** (utilizzando i **migliori iperparametri**) sulle **immagini originali** pre-riduzione dimensionale (X_train) e ne sono state valutate le prestazioni (X_test)

Modello	Accuratezza	Precisione	Sensibilità	F1-Score	ROC-AUC
SVM	0.810	0.816	0.810	0.801	0.983
Rete Neurale	0.848	0.858	0.849	0.850	0.975



Commento

La riduzione dimensionale consente di **mantenere prestazioni comparabili ai dati originali**. La PCA risulta efficace per la Rete Neurale, **migliorando di poco l'accuratezza**, mentre per SVM le **prestazioni restano quasi invariate**, confermando la robustezza dei modelli anche in uno spazio a dimensionalità ridotta

 Per osservare in dettaglio la fase di addestramento dei modelli al variare degli iperparametri, consultare il file **log.txt** con l'output del terminale

Extra 2: Confronto Dataset: «Olivetti Faces»

Verifica dei risultati ottenuti in relazione a un secondo dataset di confronto

Al fine di **validare la robustezza dei risultati**, l'analisi è stata estesa a un secondo dataset, **Olivetti Faces**. La pipeline di estrazione delle feature (PCA, Autoencoder) e classificazione (SVM, Rete Neurale) è stata **replicata integralmente** per un **confronto diretto delle performance**

STATISTICHE DESCRITTIVE DEL DATASET

📏 Dimensioni

Numero di esempi

400 immagini (Grayscale)

Dimensione delle immagini

64 × 64 pixel

Vettore delle feature

D = 4096

Classi

K = 40

✂️ Partizionamento

Training Set

320

80%

Test Set

80

20%

Stratificato per classe


📊 Statistiche dei Pixel

Intervallo originale

[0, 255]

Post-standardizzazione

$\mu = 0, \sigma = 1$



Extra 2: Confronto Dataset: «Olivetti Faces»

Descrizione vantaggi e svantaggi del dataset

Creato presso gli **AT&T Laboratories Cambridge** (ex Olivetti Research Laboratory) tra il 1992 e il 1994, è un **classico del Machine Learning** per il riconoscimento facciale

✓ Vantaggi

- 1 Sfondo Uniforme**
Tutte le immagini hanno uno sfondo omogeneo. L'algoritmo non deve imparare a ignorare oggetti secondari
- 2 Varianza Limitata**
10 foto dello stesso soggetto cambiano solo per dettagli minimi
- 3 Illuminazione Fissa**
La luce è frontale e uniforme. Non ci sono ombre esagerate che coprono metà viso
- 4 Allineamento Perfetto**
Gli occhi e la bocca si trovano sempre nelle stesse coordinate. Non serve un pre-processing di allineamento

✗ Limiti

- 1 Irrealistico**
Non riflette le condizioni del mondo reale
- 2 Pochi Dati**
Poche immagini per addestrare modelli, con rischio overfitting

💡 Approfondimento

Essendo **piccolo**, permette di **addestrare modelli** come SVM, PCA o Autoencoder **in poco tempo**.

Funge da **sanity check** per i modelli data la sua semplicità ed è usato in didattica per visualizzare le eigenfaces con **risultati puliti e interpretabili**

Extra 2: Confronto Dataset: «Olivetti Faces»

Applicazione Autoencoder e PCA sulle immagini del dataset

È stata utilizzata la **stessa pipeline di analisi** sviluppata per il dataset principale, per garantire che **eventuali differenze di prestazione** siano dovute solo ai dati, evitando **bias**

Q Faccia Media: Olivetti Faces



 **Zone Nitide Accentuate**
Occhi e naso simili tra tutti i volti

 **Poche Zone Sfocate**
Bocca e zone esterne del volto

Q Faccia Media: Labeled Faces in the Wild



 **Poche Zone Nitide**
Occhi e naso molto diversi tra i volti

 **Molte Zone Sfocate**
Soggetti con alta **variabilità nei tratti**




Commento

Mentre su Olivetti Faces la riduzione dimensionale **preserva l'identità** in modo fedele (volto nitido), su LFW la **variabilità intra-classe** influisce pesantemente. Questo preannuncia un **gap prestazionale**, in quanto l'assenza di allineamento in LFW impone un **limite all'accuratezza dei modelli lineari**


Extra 2: Confronto Dataset: «Olivetti Faces»

Confronto dei grafici significativi: Varianza spiegata cumulativa

Olivetti Faces



Labeled Faces in the Wild





Commento

A parità di varianza spiegata cumulativa, Olivetti Faces richiede un **numero inferiore di componenti**, indicando come i **dettagli delle immagini** nel nuovo dataset siano **più significativi** e preservino meglio la varianza rispetto a quelli del dataset principale

Extra 2: Confronto Dataset: «Olivetti Faces»

Confronto dei grafici significativi: Eigenfaces




Commento

Le eigenfaces di Olivetti **appaiono riconoscibili**, indicando come la **varianza dipenda dall'identità**. In LFW le prime componenti rappresentano **gradienti di illuminazione**, confermando che in scenari reali il modello tende a **codificare la luce ambientale** prima dei tratti somatici

Extra 2: Confronto Dataset: «Olivetti Faces»

Confronto dei grafici significativi: Errore di ricostruzione




Commento

Su Olivetti **i dettagli sono preservati**, mentre su LFW viene introdotto **molto rumore** a causa della varianza dello sfondo. L'Autoencoder soffre di **over-smoothing**, poiché tende a **mediare i volti** perdendo i tratti distintivi


Extra 2: Confronto Dataset: «Olivetti Faces»

Confronto dei grafici significativi: Studio di ablazione del numero di componenti – PCA

Olivetti Faces



Labeled Faces in the Wild




Commento

Per PCA, il confronto mostra come **la complessità del dataset influenzi la selezione delle feature**. In Olivetti Faces, **l'accuratezza sale e si stabilizza**, indicando che tutte le componenti portano informazione utile. In LFW, **l'accuratezza cala** dopo le 100 componenti: questo dimostra che le **ultime componenti principali** (a bassa varianza) stanno codificando **rumore di fondo** e dettagli irrilevanti.


Extra 2: Confronto Dataset: «Olivetti Faces»

Confronto dei grafici significativi: Studio di ablazione del numero di componenti – Autoencoder

Olivetti Faces



Labeled Faces in the Wild



Paradosso: A circa 75 componenti il modello comprime benissimo, ma distingue male, poiché la rappresentazione latente è troppo densa. Aumentando le dimensioni, si sacrifica un po' di ricostruzione per migliorare la separazione



Commento

Per Autoencoder, in Olivetti Faces l'aumento della dimensione latente a 150 **migliora le performance**, indicando che il modello sfrutta le sue capacità per **codificare dettagli fini** dell'identità. In LFW si osserva **overfitting sul rumore** oltre le 100 dimensioni: l'accuratezza crolla e **l'errore di ricostruzione aumenta**. Il modello inizia a codificare variazioni irrilevanti a discapito delle feature discriminative

Extra 2: Confronto Dataset: «Olivetti Faces»

Metriche di classificazione e risultati numerici per riconoscimento facciale

Dataset	Modello	Feature	Accuratezza	Precisione	Sensibilità	F1-Score	ROC-AUC
Olivetti Faces	SVM	PCA	0.9625	0.9750	0.9625	0.9600	0.9994
Olivetti Faces	SVM	Autoencoder	0.9375	0.9625	0.9375	0.9350	0.9994
Olivetti Faces	Rete Neurale	PCA	0.9250	0.9350	0.9250	0.9160	1.0000
Olivetti Faces	Rete Neurale	Autoencoder	0.9500	0.9458	0.9500	0.9400	0.9994
LFW	SVM	PCA	0.8062	0.7846	0.7145	0.7423	0.9800
LFW	SVM	Autoencoder	0.7984	0.7957	0.7176	0.7474	0.9710
LFW	Rete Neurale	PCA	0.8527	0.8100	0.8131	0.8086	0.9803
LFW	Rete Neurale	Autoencoder	0.8217	0.7705	0.8026	0.7853	0.9714

 Per osservare in dettaglio le **curve ROC** e le **matrici di confusione**, consultare i grafici presenti nel branch relativo del repository GitHub

Extra 2: Confronto Dataset: «Olivetti Faces»

Commento dei risultati emersi dal confronto

Crollo dell'Accuratezza

Si registra un **calo delle performance** di circa l'11-15% passando dall'**ambiente controllato** di Olivetti Faces (96.25%) a quello **variabile** di LFW (85.27%). Questo divario evidenzia come **la varianza ambientale** (luce, posa) di LFW **domini sull'identità**, rendendo la compressione più ardua e limitando **la capacità del modello di generalizzare** rispetto ai dati ideali

Efficacia della Riduzione Dimensionale (PCA vs Autoencoder)

Su Olivetti **entrambe le tecniche eccellono**: l'Autoencoder raggiunge il **minimo errore di ricostruzione**, ma la PCA **fornisce feature più discriminanti** per l'SVM (96.25% vs 93.75%).

Su LFW la PCA mantiene un **vantaggio marginale sull'Autoencoder** (85.27% vs 82.17% con Rete Neurale), che però tende a **sfocare i dettagli per minimizzare l'errore** su volti non allineati, perdendo tratti distintivi necessari alla classificazione

Classificazione (Linearità vs Non-Linearità)

Nell'ambiente controllato di Olivetti Faces, i dati sono **ben separabili linearmente**: il classificatore SVM supera la Rete Neurale (0.96 vs 0.95).

Nell'ambiente reale di LFW, la **complessità richiede modelli non lineari**: la Rete Neurale supera l'SVM di circa il 5% (0.85 vs 0.80), dimostrando una **maggiore capacità di gestire il rumore** residuo nelle feature

Bibliografia

Fonti della ricerca

Abdullah, M. I., Islam, M. N., Bala, D., Hossain, M. A., Rahman, M. A., & Islam, M. S. (2025). Efficient Face Detection and Recognition with PCA and Eigenfaces: A Comprehensive Analysis. *International Journal of Advanced Networking and Applications*, 17(1), 6705–6718.

Devi, S., Saini, J., Kaur, H., & Kaur, H. (2024). Face Classification & Recognition Using Stacking Ensemble Learning with Principal Component Analysis Approach. In *2024 Third International Conference on Electrical, Electronics, Information and Communication Technologies (ICEEICT)*, Trichirappalli, India: IEEE, pp. 1–8. doi: 10.1109/ICEEICT61591.2024.10718476

Huang, G., Mattar, M., Berg, T., & Learned-Miller, E. (2008). Labeled Faces in the Wild: A Database for Studying Face Recognition in Unconstrained Environments. Tech. rep., ott. 2008.

Kayal, S. (2013). Face verification experiments on the LFW database with simple features, metrics and classifiers. In *nDS '13; Proceedings of the 8th International Workshop on Multidimensional Systems*, pp. 1–6.

Meedeniya, D. A., & Ratnaweera, D. A. A. C. (2007). Enhanced face recognition through variation of Principle Component Analysis (PCA). In *2007 International Conference on Industrial and Information Systems*, Peradeniya, Sri Lanka: IEEE, pp. 347–352. doi: 10.1109/ICIINFS.2007.4579200

Wang, Y., Yao, H., & Zhao, S. (2016). Auto-encoder based dimensionality reduction. *Neurocomputing*, 184, 232–242. doi: 10.1016/j.neucom.2015.08.104



Grazie per l'attenzione

 Codice e documentazione disponibili nel **repository**

<https://git.new/Gb69fEp>